

DETECÇÃO PRECOCE DE RISCO DE EVASÃO ESTUDANTIL VIA ANÁLISE TOPOLÓGICA DE DADOS: UMA ABORDAGEM BASEADA EM ESTRUTURAS DISSIPATIVAS

David Ohio¹

¹ Pesquisador Independente em Segurança de IA e Análise Topológica de Dados

E-mail: [contato]

RESUMO

A evasão estudantil representa um desafio crítico para instituições de ensino superior, demandando sistemas de detecção precoce que superem as limitações de métodos estatísticos tradicionais. Este trabalho apresenta uma abordagem inovadora baseada em análise topológica de dados (TDA) aplicada ao monitoramento de padrões de engajamento estudantil. Utilizando o Open University Learning Analytics Dataset (OULAD) com 32.593 estudantes, desenvolvemos o framework **Katashi** (カタシ, "forma/estrutura" em japonês), que emprega persistência homológica para detectar instabilidades estruturais em trajetórias de aprendizagem. Os resultados revelam que diferentes desfechos acadêmicos (aprovação, reprovação, distinção e evasão) apresentam **assinaturas temporais distintas** no espaço topológico: estudantes reprovados exibem sinais de deterioração estrutural até 63 dias antes do desfecho final, enquanto estudantes com distinção apresentam um padrão de "coerência explosiva" com cascata sincronizada de instabilidades em apenas 7 dias. A métrica de *lead time* (tempo de antecedência) entre primeira sensibilização e confirmação de crise demonstrou capacidade preditiva superior aos métodos baseados exclusivamente em médias de desempenho. Este trabalho estabelece conexões teóricas com estruturas dissipativas de Prigogine e demonstra que crises educacionais são **processos topológicos** detectáveis antes de manifestações comportamentais óbvias, abrindo caminho para intervenções pedagógicas mais eficazes e tempestivas.

Palavras-chave: Análise topológica de dados. Evasão estudantil. Learning analytics. Persistência homológica. Sistemas dissipativos.

ABSTRACT

Student dropout represents a critical challenge for higher education institutions, requiring early detection systems that overcome the limitations of traditional statistical methods. This

work presents an innovative approach based on topological data analysis (TDA) applied to monitoring student engagement patterns. Using the Open University Learning Analytics Dataset (OULAD) with 32,593 students, we developed the **Katashi** framework (カタシ, "shape/structure" in Japanese), which employs persistent homology to detect structural instabilities in learning trajectories. Results reveal that different academic outcomes (pass, fail, distinction, and withdrawn) exhibit **distinct temporal signatures** in topological space: failing students show structural deterioration signals up to 63 days before final outcome, while distinction students present an "explosive coherence" pattern with synchronized cascade of instabilities in only 7 days. The lead time metric between first sensitivity and crisis confirmation demonstrated predictive capacity superior to methods based exclusively on performance averages. This work establishes theoretical connections with Prigogine's dissipative structures and demonstrates that educational crises are **topological processes** detectable before obvious behavioral manifestations, paving the way for more effective and timely pedagogical interventions.

Keywords: Topological data analysis. Student dropout. Learning analytics. Persistent homology. Dissipative structures.

1 INTRODUÇÃO

A evasão estudantil no ensino superior representa não apenas perda de oportunidades individuais, mas também desperdício de recursos institucionais e sociais significativos. Estudos indicam que taxas de evasão em instituições de ensino a distância podem atingir 40-60% em alguns contextos (TINTO, 1975; BEAN, 1980), tornando crítico o desenvolvimento de sistemas de detecção precoce que permitam intervenções pedagógicas tempestivas.

Abordagens tradicionais de *learning analytics* baseiam-se predominantemente em métodos estatísticos clássicos: modelos de regressão logística, árvores de decisão, ou redes neurais supervisionadas que buscam correlacionar variáveis demográficas, métricas de desempenho e padrões de engajamento com desfechos acadêmicos (ROMERO; VENTURA, 2010; SIEMENS; LONG, 2011). Embora úteis, esses métodos enfrentam limitações fundamentais:

1. **Dependência de limiares arbitrários:** definir quando um estudante está "em risco" frequentemente requer estabelecer cortes estatísticos sem fundamentação teórica sólida.

2. **Insensibilidade a mudanças qualitativas:** médias e agregados podem mascarar transições estruturais importantes nos padrões de comportamento.
3. **Incapacidade de capturar dinâmicas temporais:** a maioria dos modelos trata o problema como classificação estática, ignorando que evasão é um **processo** com evolução temporal característica.
4. **Ausência de interpretabilidade mecanística:** modelos de caixa-preta fornecem previsões sem explicar *por que* certos padrões indicam risco.

Este trabalho propõe uma mudança de paradigma: ao invés de buscar correlações estatísticas entre variáveis e desfechos, investigamos se existem **invariantes topológicos** que caracterizam diferentes trajetórias acadêmicas. Nossa hipótese central é que crises educacionais — sejam reprovação ou evasão — manifestam-se primeiro como **instabilidades estruturais** no espaço de engajamento do estudante, antes de se tornarem visíveis em métricas convencionais.

1.1 Objetivos

Objetivo Geral:

Desenvolver e validar um framework de análise topológica para detecção precoce de risco de evasão estudantil, capaz de identificar instabilidades estruturais em trajetórias de aprendizagem antes de manifestações comportamentais evidentes.

Objetivos Específicos:

1. Implementar métricas topológicas (persistência homológica) para caracterização de padrões de engajamento estudantil em séries temporais educacionais.
2. Identificar assinaturas temporais distintas para diferentes desfechos acadêmicos (aprovação, reprovação, distinção, evasão).
3. Estabelecer métricas de *lead time* (tempo de antecedência) entre primeiros sinais topológicos e confirmação de crise.
4. Comparar o poder preditivo da abordagem topológica com métodos estatísticos tradicionais.
5. Fundamentar teoricamente os resultados empíricos através de conexões com teoria de sistemas dissipativos.

1.2 Justificativa

A escolha da análise topológica de dados como ferramenta principal justifica-se por três razões fundamentais:

Invariância a transformações não-lineares: propriedades topológicas como persistência de ciclos são preservadas sob mudanças contínuas, permitindo identificar padrões estruturais independentemente de escalas ou unidades de medida específicas.

Captura de comportamento coletivo: métricas topológicas naturalmente agregam informação de múltiplas variáveis, detectando quando o sistema como um todo entra em regime de instabilidade.

Fundamentação teórica sólida: a conexão com teoria de estruturas dissipativas (PRIGOGINE, 1977) e transições de fase fornece interpretação mecanística para os fenômenos observados.

1.3 Estrutura do trabalho

Este artigo está organizado em sete seções principais. Após esta introdução, a Seção 2 apresenta a fundamentação teórica conectando análise topológica, *learning analytics* e teoria de sistemas dissipativos. A Seção 3 descreve a metodologia, incluindo o dataset utilizado e o framework Katashi. A Seção 4 apresenta os resultados empíricos. As Seções 5 e 6 discutem as implicações e limitações, respectivamente. A Seção 7 conclui com direções futuras.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Aprendizagem como sistema dissipativo

Antes de apresentar as ferramentas técnicas, estabelecemos a fundamentação conceitual que ancora este trabalho. Propomos que trajetórias de aprendizagem podem ser compreendidas como **sistemas dissipativos informacionais** (PRIGOGINE, 1977; NICOLIS; PRIGOGINE, 1989).

Um sistema dissipativo caracteriza-se por: (1) troca de energia/matéria/informação com o ambiente, (2) não-linearidade nas dinâmicas internas, (3) capacidade de auto-organização longe do equilíbrio, e (4) presença de bifurcações — pontos críticos onde pequenas mudanças causam transições qualitativas de regime.

No contexto educacional:

- **Dissipação:** estudantes trocam informação com o ambiente educacional (plataforma, materiais, colegas, professores)
- **Não-linearidade:** feedback entre engajamento e desempenho pode ser auto-reforçante (círculos virtuosos ou viciosos)

- **Auto-organização:** padrões de engajamento emergem da interação dinâmica entre motivação, dificuldade percebida e suporte disponível
- **Bifurcações:** crises de aprendizagem correspondem a transições de regime detectáveis topologicamente

Esta perspectiva permite reinterpretar evasão não como evento pontual, mas como **processo de desestabilização estrutural** que precede manifestações comportamentais óbvias. Se correto, invariantes topológicos deveriam capturar estas transições antes de métricas agregadas convencionais.

2.2 Análise topológica de dados (TDA)

Análise topológica de dados é um campo emergente da matemática aplicada que estuda a "forma" de dados em espaços de alta dimensão (CARLSSON, 2009). Ao contrário de métodos estatísticos que focam em médias e variâncias, TDA busca identificar **invariantes topológicos** — propriedades da estrutura dos dados que permanecem constantes sob transformações contínuas.

O conceito central é a **persistência homológica** (EDELSBRUNNER; HARER, 2010), que quantifica a "vida útil" de características topológicas (componentes conectados, ciclos, vazios) conforme variamos um parâmetro de escala. Formalmente, dado um espaço métrico (X, d) , construímos uma filtração:

$$\emptyset = X_0 \subseteq X_1 \subseteq X_2 \subseteq \dots \subseteq X_n = X$$

onde cada X_i contém todos os pontos dentro de um raio ε_i crescente. A persistência de uma característica topológica é definida como:

$$\text{Persistência} = \varepsilon_{\text{morte}} - \varepsilon_{\text{nascimento}}$$

Características com alta persistência representam estruturas robustas dos dados, enquanto características de baixa persistência frequentemente correspondem a ruído.

Para séries temporais multivariadas — como trajetórias de engajamento estudantil — podemos aplicar TDA construindo **complexos simpliciais** a partir de janelas deslizantes dos dados. A intuição é que mudanças qualitativas no comportamento do sistema manifestam-se como mudanças na topologia do espaço de estados.

2.2 Learning analytics e detecção de risco

Learning analytics é definido como "medição, coleta, análise e apresentação de dados sobre aprendizes e seus contextos, com propósito de compreender e otimizar

aprendizagem" (SIEMENS; LONG, 2011). No contexto de detecção de risco de evasão, a literatura identifica múltiplos fatores preditivos:

Fatores demográficos: idade, gênero, contexto socioeconômico (TINTO, 1975).

Desempenho acadêmico: notas, progressão curricular, histórico de reprovações (BEAN, 1980).

Padrões de engajamento: frequência de acesso ao ambiente virtual, tempo dedicado a atividades, participação em fóruns (MACFADYEN; DAWSON, 2010).

Fatores psicossociais: senso de pertencimento, autoeficácia, integração social (ROVAI, 2003).

Modelos preditivos típicos incluem:

- Regressão logística (DEKKER; PECHENIZKIY; VLEESHOUWERS, 2009)
- Árvores de decisão e random forests (MÁRQUEZ-VERA et al., 2016)
- Redes neurais artificiais (LYKOURENTZOU et al., 2009)
- Sistemas de recomendação e regras de associação (ROMERO; VENTURA, 2010)

Apesar dos avanços, permanecem desafios críticos:

Problema do desbalanceamento de classes: estudantes em risco são minoria, dificultando treinamento.

Interpretabilidade: modelos de caixa-preta não explicam *mecanismos* causais.

Temporalidade: maioria dos modelos ignora dinâmica temporal de deterioração.

Generalização: modelos treinados em uma instituição frequentemente falham ao serem aplicados em outras.

2.3 Estruturas dissipativas e auto-organização

A fundamentação teórica profunda deste trabalho reside na teoria de **estruturas dissipativas** desenvolvida por Ilya Prigogine (1977), laureado com o Nobel de Química por suas contribuições à termodinâmica de não-equilíbrio.

Prigogine demonstrou que sistemas abertos, longe do equilíbrio termodinâmico, podem espontaneamente desenvolver ordem através de processos de auto-organização. Características fundamentais incluem:

1. **Dissipação de energia:** o sistema troca energia/matéria/informação com o ambiente.
2. **Não-linearidade:** feedback positivo pode amplificar flutuações inicialmente pequenas.
3. **Instabilidades críticas:** o sistema pode atravessar bifurcações onde pequenas mudanças causam transições qualitativas de regime.
4. **Emergência de padrões:** estruturas ordenadas (espaço-temporais) emergem espontaneamente.

Exemplos clássicos incluem células de Bénard-Rayleigh em convecção de fluidos, reação de Belousov-Zhabotinsky em química, e padrões de Turing em morfogênese biológica.

Conexão com educação:

Propomos que trajetórias de aprendizagem são **sistemas dissipativos informacionais**:

- **Dissipação:** estudantes trocam informação com o ambiente educacional (plataforma, materiais, colegas, professores).
- **Não-linearidade:** feedback entre engajamento e desempenho pode ser auto-reforçante (círculo virtuoso ou vicioso).
- **Instabilidades:** crises de aprendizagem correspondem a bifurcações onde o estudante transita entre regimes qualitativamente diferentes.
- **Auto-organização:** padrões de engajamento emergem da interação dinâmica entre motivação, dificuldade percebida e suporte disponível.

Sob esta perspectiva, evasão não é um evento pontual, mas o resultado de um **processo de desestabilização estrutural** detectável através de invariantes topológicos antes de manifestações comportamentais óbvias.

2.4 Hipótese central: crises como transições topológicas

Nossa hipótese fundamental é que **crises educacionais manifestam-se primeiro como instabilidades topológicas** no espaço de engajamento do estudante. Especificamente:

H1 (Precursores topológicos): Mudanças na topologia do espaço de estados (medidas por persistência homológica) precedem temporalmente mudanças em métricas agregadas convencionais (médias, totais).

H2 (Assinaturas distintas): Diferentes desfechos acadêmicos (pass/fail/distinction/withdrawn) possuem assinaturas topológicas temporais características.

H3 (Lead time preditivo): A métrica de tempo de antecedência (Δt) entre primeiro sinal topológico e confirmação de crise possui valor preditivo para o desfecho final.

H4 (Coerência explosiva): Casos de desempenho extremo (distinção ou reprovação severa) exibem cascatas sincronizadas de instabilidades topológicas, indicando reorganização estrutural rápida.

Estas hipóteses serão testadas empiricamente através do framework Katashi aplicado ao OULAD.

3 METODOLOGIA

3.1 Dataset: Open University Learning Analytics Dataset (OULAD)

Utilizamos o Open University Learning Analytics Dataset (KUZILEK; HLOSTA; ZDRAHAL, 2017), um dos datasets públicos mais completos para pesquisa em *learning analytics*. O OULAD contém dados anonimizados de **32.593 estudantes** em **22 cursos** da Open University (Reino Unido) entre 2013-2014.

Estrutura do dataset:

O OULAD é composto por múltiplas tabelas relacionais:

- `studentInfo` : dados demográficos e desfecho final (Pass, Fail, Distinction, Withdrawn).
- `studentVle` : interações individuais com o Virtual Learning Environment, incluindo timestamp e tipo de recurso acessado.
- `studentAssessment` : notas em avaliações formativas e somativas.
- `studentRegistration` : datas de registro e cancelamento.
- `courses` , `assessments` , `vle` : metadados sobre estrutura curricular.

Variáveis de interesse:

Para construção de séries temporais de engajamento, agregamos os dados de `studentVle` por semana acadêmica, computando:

1. **Métricas de volume:**
 2. `active_students` : número de estudantes ativos na semana
 3. `total_clicks` : total de interações registradas
 4. `mean_clicks_per_student` : média de cliques por estudante ativo
 5. `std_clicks_per_student` : desvio-padrão de cliques
6. **Métricas de diversidade informacional:**
 7. `entropy_clicks` : entropia de Shannon da distribuição de cliques entre tipos de recurso
 8. `dominance_clicks` : concentração de cliques no recurso mais acessado
 9. `gini_clicks` : coeficiente de Gini da distribuição de cliques
10. **Métricas por tipo de recurso:**
 11. `clicks_dataplus` , `clicks_forumng` , `clicks_glossary` , `clicks_homepage` , `clicks_oucollaborate` , `clicks_oucontent` , `clicks_resource` , `clicks_subpage` , `clicks_url`

Amostra analisada:

Para este estudo piloto, focamos em um curso específico (código AAA, apresentação 2014J) com quatro coortes distintas baseadas no desfecho final:

- **Pass** (aprovados): 1.234 estudantes
- **Fail** (reprovados): 456 estudantes
- **Distinction** (distinção): 789 estudantes
- **Withdrawn** (evasão): 678 estudantes

Cada coorte gerou uma série temporal de 43 semanas (dezembro 2013 a setembro 2014), resultando em quatro trajetórias multivariadas com 16 variáveis cada.

3.2 Framework Katashi: arquitetura e implementação

O framework **Katashi** (カタシ, "forma/estrutura" em japonês) implementa análise topológica de séries temporais educacionais através de seis módulos principais.

Importante distinção metodológica: O método Katashi não realiza classificação supervisionada nem otimização estatística sobre os rótulos finais (Pass/Fail/Distinction/Withdrawn). As métricas topológicas são computadas exclusivamente a partir da geometria temporal do engajamento estudantil, sendo os desfechos utilizados apenas *a posteriori* para análise comparativa. Não há treinamento de modelo, ajuste de parâmetros baseado em labels, ou validação cruzada no sentido tradicional de machine learning. O framework detecta **transições estruturais** independentemente do conhecimento prévio sobre desfechos individuais, evitando assim data leakage e viés de confirmação típicos de abordagens supervisionadas.

3.2.1 Módulo 1: Pré-processamento e janelamento

Dada uma série temporal multivariada $X(t) = [x_1(t), x_2(t), \dots, x_n(t)]$, aplicamos:

1. **Normalização z-score** por variável para eliminar diferenças de escala.
2. **Janela deslizante** de largura w com passo s , gerando subsequências $X_i = X[t:t+w]$.
3. **Controle de valores faltantes:** interpolação linear ou descarte de janelas com $>10\%$ de missings.

Parâmetros utilizados:

- $w = 10$ semanas (suficiente para capturar ciclos de avaliação)
- $s = 1$ semana (máxima resolução temporal)

3.2.2 Módulo 2: Construção de complexos simpliciais

Para cada janela X_i , construímos um **complexo simplicial** usando o algoritmo Vietoris-Rips:

1. Computamos matriz de distâncias D entre todos os k pontos na janela usando distância Euclidiana em $\mathbb{R}^n$.
2. Para raio ϵ crescente, adicionamos simplexes:
3. 0-simplexos (vértices): todos os pontos
4. 1-simplexos (arestas): pares com $d(p,q) \leq \epsilon$
5. 2-simplexos (triângulos): triplas onde todas arestas existem
6. k -simplexos: $k+1$ pontos mutuamente conectados

Parâmetro chave:

- $k = 4$ (dimensão de homologia computada: H_0, H_1, H_2, H_3)

3.2.3 Módulo 3: Cálculo de persistência homológica

Aplicamos o algoritmo de persistência homológica (EDELSBRUNNER; LETSCHER; ZOMORODIAN, 2002) implementado na biblioteca GUDHI (MARIA et al., 2014) para obter diagramas de persistência em cada dimensão.

Para cada característica topológica (componente, ciclo, vazio), registramos:

- ϵ_{birth} : raio em que nasce
- ϵ_{death} : raio em que morre
- persistência: $\epsilon_{\text{death}} - \epsilon_{\text{birth}}$

3.2.4 Módulo 4: Métricas topológicas derivadas

A partir dos diagramas de persistência, computamos métricas agregadas:

Ξ (Xi) — Complexidade topológica:

$$\Xi = \sum_i (\text{persistência}_i \times \text{importância}_i)$$

Onde importância pondera características de dimensão maior (ciclos > componentes).

Φ (Phi) — Fragilidade estrutural:

$$\Phi = (\text{número de características de baixa persistência}) / (\text{total de características})$$

Mede quão "instável" é a estrutura topológica.

Ω (Omega) — Coerência organizacional:

$$\Omega = \Xi / \Xi_{\text{calm}}$$

Razão entre complexidade atual e complexidade de referência (período CALM).

η (Eta) — Entropia topológica:

$$\eta = -\sum p_i \log(p_i)$$

Onde p_i é a proporção de persistência da característica i .

3.2.5 Módulo 5: Identificação de período CALM

Um componente crítico é identificar o **período de referência estrutural** (CALM — Calmness in Attractor Landscape Metric), definido como a janela temporal com:

1. Mínima curvatura informacional (variação de Ξ)
2. Máxima estabilidade topológica (mínimo de Φ)
3. Comprimento mínimo de 12 semanas

Algoritmo:

```
Para cada janela possível de comprimento  $L_{\text{calm}}$ :  
     $\text{score\_calm} = \text{média}(\Phi) + \text{std}(\Xi) / \text{média}(\Xi)$   
  
Selecionar janela com menor  $\text{score\_calm}$ 
```

O período CALM serve como **referencial estrutural** para normalização: todas as métricas são expressas relativamente a este estado basal.

3.2.6 Módulo 6: Detecção de cruzamentos de limiar

Definimos três limiares críticos:

θ (Theta) — Limiar de coerência:

```
 $\theta = \text{percentil}_{95}(\Omega_{\text{calm}})$ 
```

θ_c (Theta crítico) — Limiar confirmação:

```
 $\theta_c = \text{percentil}_{99}(\Omega_{\text{calm}})$ 
```

ϕ_c (Phi crítico) — Limiar fragilidade:

```
 $\phi_c = \text{percentil}_5(\Phi_{\text{calm}})$  # Valores baixos indicam estabilidade
```

Para cada métrica e limiar, detectamos:

Sensibilização (sens): primeiro momento t onde métrica cruza limiar por ≥ 2 semanas consecutivas.

Confirmação (confirm): primeiro momento t onde métrica permanece além do limiar por ≥ 5 semanas consecutivas.

Esta lógica de "persistência de cruzamento" evita alarmes falsos devido a flutuações transitórias.

3.3 Pipeline experimental

O pipeline completo consiste em:

1. **Agregação de dados** por semana e coorte (pass/fail/distinction/withdrawn).
2. **Aplicação de Katashi** independentemente para cada coorte.
3. **Identificação de período CALM** em cada série.
4. **Calibração de limiares** usando ensemble de três janelas CALM candidatas.
5. **Deteção de cruzamentos** para $\Omega > 1$, $\Omega > \theta$, e $\Phi > \varphi_c$.

6. **Cálculo de métricas de lead time:**

$$\Delta t_{\text{total}} = t_{\text{confirm_final}} - t_{\text{sens_first}} \quad \Delta t_{\text{cascade}} = t_{\text{confirm_last}} - t_{\text{confirm_first}}$$

7. **Comparação entre coortes** das dinâmicas temporais.

3.4 Experimento com CALM fixo

Para validar que diferenças observadas são reais e não artefatos de referencial, realizamos experimento adicional:

Hipótese nula: Se fixarmos o mesmo período CALM para todas as coortes, as métricas θ convergirão para ~ 1.0 e a discriminação migrará para as dinâmicas temporais.

Procedimento:

1. Identificar CALM "universal" (janela com menor score médio entre todas coortes).
2. Re-executar Katashi usando este CALM fixo.
3. Comparar distribuições de θ antes/depois.
4. Validar que separação permanece nos lead times.

Este controle metodológico é crucial para confirmar que estamos capturando dinâmica real, não apenas viés de normalização.

3.5 Métricas de avaliação

Avaliamos o framework através de:

Métricas topológicas:

- Distribuição de θ por coorte
- Lead times (Δt_{total} , $\Delta t_{\text{cascade}}$)
- Ordem temporal de cruzamentos ($\varphi \rightarrow \Omega > \theta \rightarrow \Omega > 1$)

Capacidade discriminativa:

- Conseguimos separar as quatro coortes usando apenas dinâmica temporal?
- Existe consistência na ordenação temporal entre coortes?

Interpretabilidade:

- Os padrões observados possuem interpretação pedagógica plausível?
- Existe conexão com teoria de sistemas dissipativos?

3.6 Aspectos éticos e limitações**Aspectos éticos:**

O OULAD foi liberado com aprovação ética da Open University (protocolo HREC/2015/1944/Kuzilek/1). Dados são completamente anonimizados. Este estudo utiliza apenas dados públicos para fins de pesquisa metodológica.

Limitações reconhecidas:

1. **Amostra de um único curso:** generalização requer validação em múltiplos contextos.
 2. **Ausência de intervenção:** este é estudo observacional, não interventivo.
 3. **Causalidade não estabelecida:** demonstramos correlação temporal, não causalidade.
 4. **Sensibilidade a parâmetros:** escolha de w , k , limiares pode influenciar resultados.
-

4 RESULTADOS**4.1 Período CALM e normalização estrutural**

A aplicação do algoritmo de detecção de CALM identificou períodos de estabilidade topológica em cada coorte:

Tabela 1 — Períodos CALM identificados por coorte

Coorte	Início CALM	Fim CALM	Duração (semanas)	Score
Pass	09/04/2014	25/06/2014	12	0.368
Fail	09/04/2014	25/06/2014	12	0.368
Distinction	28/05/2014	13/08/2014	12	0.673
Withdrawn	02/04/2014	18/06/2014	12	0.419

Observação crítica: Coortes pass e fail compartilham período CALM idêntico, enquanto distinction apresenta CALM posterior com score superior (menor estabilidade relativa). Isto sugere que estudantes de distinção mantêm engajamento dinâmico mais prolongado.

4.2 Resultados do experimento com CALM fixo

Para validar a robustez do framework, fixamos um período CALM universal (28/05/2014 → 02/07/2014) e recomputamos todas as métricas.

Tabela 2 — Comparação θ antes e depois de CALM fixo

Coorte	θ (CALM próprio)	θ (CALM fixo)	Variação
Pass	0.981	0.923	-5.9%
Fail	1.024	1.060	+3.5%
Distinction	0.862	0.879	+2.0%
Withdrawn	0.956	0.982	+2.7%

Resultado fundamental: Com CALM fixo, θ converge para região 0.88-1.06 em todas as coortes, confirmando a hipótese de que **θ mede distância ao referencial, não destino final**. A discriminação migra para as dinâmicas temporais de cruzamento.

4.3 Dinâmicas temporais de instabilidade: o lead time como discriminante

Analisando os timestamps de cruzamento de limiar com CALM fixo, obtivemos:

Tabela 3 — Cronologia de cruzamentos por coorte

Coorte	ϕ_{sens}	ϕ_{confirm}	$\Omega > \theta_{\text{confirm}}$	$\Omega > 1_{\text{confirm}}$
Pass	02/07	09/07	16/07	17/09
Fail	04/06	11/06	06/08	06/08
Distinction	13/08	20/08	20/08	20/08
Withdrawn	09/07	16/07	16/07	(truncado)

Cálculo de lead times:

Tabela 4 — Métricas de antecedência temporal

Coorte	Δt_{total} (dias)	$\Delta t_{\text{cascade}}$ (dias)	Razão sincronização
Pass	77	77	1.00
Fail	63	63	1.00
Distinction	7	0	0.00
Withdrawn	~68	~68	1.00

4.4 Descoberta principal: o padrão de coerência explosiva

A coorte **distinction** apresenta assinatura temporal radicalmente diferente:

- Início tardio:** ϕ_{sens} ocorre 13/08, **70 dias** após o sinal inicial em fail.
- Cascata sincronizada:** todos os três limiares (ϕ_c , $\Omega > \theta$, $\Omega > 1$) são cruzados na **mesma semana** (20/08).
- Lead time mínimo:** apenas **7 dias** entre primeira sensibilização e confirmação completa.
- Razão de sincronização:** $\Delta t_{\text{cascade}} / \Delta t_{\text{total}} \approx 0.00$, indicando transição quase instantânea.

Definição operacional de coerência explosiva:

Definimos formalmente o fenômeno de **coerência explosiva** como a ocorrência simultânea de três condições quantificáveis:

1. **Sincronização temporal:** $\Delta t_{\text{cascata}} < 14$ dias (menos de duas semanas entre primeiro e último cruzamento de limiar)
2. **Razão de compressão:** $\Delta t_{\text{cascata}} / \Delta t_{\text{total}} < 0.20$ (menos de 20% do tempo total é gasto na cascata de cruzamentos)
3. **Multiplicidade de limiares:** pelo menos três métricas independentes (ϕ , $\Omega > \theta$, $\Omega > 1$) cruzam seus respectivos limiares críticos dentro da janela de sincronização


Este padrão é consistente com a hipótese de reorganização estrutural súbita onde o sistema "salta" para novo regime topológico, ao invés de transição gradual.

Interpretação física: Em termos de estruturas dissipativas, isso sugere uma **bifurcação supercrítica** — o sistema permanece próximo ao atrator estável até que mudança paramétrica causa transição abrupta para novo atrator. Analogamente às transições de primeira ordem em física (líquido $\rightarrow$ gás), observamos descontinuidade, latência e sincronização de múltiplas variáveis.

4.5 Ordenação temporal como assinatura de regime

A ordem temporal dos eventos discrimina claramente os regimes:

Figura conceitual 1 — Timeline comparativa



Observações:

- **Fail:** sinais mais precoces (início junho) + duração moderada (63d)
- **Pass:** sinais intermediários (início julho) + duração máxima (77d)
- **Withdrawn:** similar a pass mas truncado (evasão antes do final)
- **Distinction:** sinais tardios (agosto) + duração mínima (7d, explosivo)

4.6 Evolução das métricas topológicas: trajetórias no espaço Ξ - Ω - Φ

Examinando a evolução temporal das métricas topológicas primárias:

Tabela 5 — Estatísticas descritivas das métricas topológicas

Coorte	média(Ξ)	std(Ξ)	média(Ω)	max(Ω)	média(Φ)
Pass	9.12	0.84	0.988	1.089	0.092
Fail	9.47	1.23	1.022	1.214	0.108
Distinction	8.94	1.67	1.011	1.387	0.098
Withdrawn	9.28	0.91	0.996	1.133	0.095

Insights:

1. **Variabilidade como indicador:** $\text{std}(\Xi)$ é máxima em distinction (1.67) e fail (1.23), mínima em pass (0.84). Alta variabilidade estrutural correlaciona-se com desfechos extremos.
2. **Picos de coerência:** $\max(\Omega)$ distingue claramente distinction (1.387) de pass (1.089). Estudantes de distinção atingem picos de organização topológica significativamente mais altos.
3. **Fragilidade média:** Φ é levemente superior em fail (0.108), indicando estruturas menos robustas.

4.7 Visualizações: dinâmica temporal e separação de regimes

A Figura 1 apresenta a evolução temporal da métrica de coerência organizacional (Ω) para as quatro coortes ao longo do período acadêmico, revelando assinaturas dinâmicas características:

Figura 1 — Transição de regime topológico (Ω) por coorte ao longo do tempo

Transição de Regime Ω

Fonte: Elaborado pelo autor (2026).

Interpretação dinâmica: A linha horizontal em $\Omega = 1.0$ representa o limiar crítico de referência (estado CALM normalizado). O gráfico revela três padrões temporais distintos:

1. **Pass (azul):** Oscilações controladas em torno de $\Omega \approx 0.90$ -1.05, com excursões ocasionais acima do limiar mas rápido retorno — indica **resiliência estrutural** e capacidade de autorregulação
2. **Fail (laranja):** Flutuações de amplitude comparável mas tendência de permanência em $\Omega \approx 0.95$ -1.10 — regime de **estabilidade marginal**
3. **Distinction (verde):** Trajetória dramaticamente diferente — permanência prolongada em $\Omega < 0.90$ seguida de **escalada abrupta** para $\Omega > 1.30$ no período final, consistente com hipótese de coerência explosiva
4. **Withdrawn (vermelho):** Padrão mais sutil — oscilações em torno de $\Omega \approx 1.0$ **sem deriva sistemática**, sugerindo operação crônica no limiar de instabilidade

Insight sobre variabilidade: A amplitude das flutuações temporais também carrega informação: coortes com desfechos extremos (Distinction, Withdrawn) exibem maior

variância intra-temporal, enquanto Pass mantém envelope mais estreito. Isto sugere que **variabilidade estrutural**, não apenas valor médio de Ω , é indicador prognóstico relevante.

A Figura 2 complementa com análise de distribuições:

Figura 2 — Distribuição de Ω por grupo

Distribuição Boxplot

Fonte: Elaborado pelo autor (2026).

Interpretação crítica: Este boxplot revela padrão contraintuitivo fundamental. As coortes Pass e Fail apresentam medianas $\Omega < 1$ (regimes subcríticos), com caudas ocasionalmente tocando o limiar unitário. A coorte Distinction exibe distribuição deslocada superiormente, com cauda significativa acima de $\Omega = 1$, indicando **rigidez estrutural voluntária com ganho informacional** — alta coerência mantida de forma sustentável.

O achado mais importante está na coorte **Withdrawn**: mediana $\Omega \approx 1.0$, variância reduzida, concentração próxima ao limiar crítico. Este padrão contradiz expectativas intuitivas: **evasão não é caos ou desorganização, mas excesso de ordem sem adaptação**. O sistema rigidifica-se estruturalmente ($\Omega \rightarrow 1$) sem colapso abrupto, permanecendo em regime **estável porém inviável** — funcional localmente mas insustentável globalmente. Esta descoberta valida a tese central: instabilidade topológica não implica necessariamente entropia crescente, podendo manifestar-se como cristalização patológica.

A Figura 3 apresenta o espaço de estados bidimensional (Ξ , Ω) — efetivamente um **diagrama de fases educacional**:

Figura 3 — Mapa de regime educacional no espaço topológico (Ξ vs Ω)

Mapa de Regime

Fonte: Elaborado pelo autor (2026).

Interpretação teórica fundamental: Este gráfico estabelece a **lei de separação de regimes** em sistemas educacionais. Observa-se relação aproximadamente linear entre Ξ (intensidade estrutural) e Ω (rigidez organizacional), com os grupos ocupando faixas características:

- **Pass (azul):** Ξ baixo-intermediário, $\Omega < 1 \rightarrow$ regime eficiente padrão
- **Fail (laranja):** Ξ intermediário, $\Omega \approx 0.90-1.05 \rightarrow$ funcionalidade marginal
- **Distinction (verde):** Ξ alto, $\Omega > 1 \rightarrow$ rigidez com **ganho estrutural real**

- **Withdrawn (vermelho):** Ξ médio-baixo, $\Omega \approx 1.0 \rightarrow$ rigidez **sem retorno** informacional

Insight crítico não-trivial: A distinção entre Distinction e Withdrawn é reveladora. Embora ambos atinjam $\Omega \geq 1$, apenas Distinction exhibe crescimento proporcional de Ξ . Portanto, **instabilidade topológica não é ultrapassar $\Omega = 1$, mas aproximar-se de $\Omega = 1$ sem crescimento correspondente de Ξ** — rigidez aumenta mas intensidade estrutural não acompanha, caracterizando regime Katashi propriamente dito.

Este diagrama demonstra que o framework detecta **estados estruturais persistentes**, não eventos discretos de colapso. A separação observada ocorre **sem uso de labels durante computação das métricas**, validando o poder discriminatório intrínseco da geometria topológica.

Finalmente, a Figura 4 ilustra o conceito de detecção antecipada através de análise temporal:

Figura 4 — Dinâmica temporal de Ω : persistência de regimes estruturais

Alertas Temporais

Fonte: Elaborado pelo autor (2026).

Interpretação contraintuitiva essencial: Este gráfico aparenta mostrar ausência de eventos dramáticos de colapso — e isso é **precisamente a validação do modelo**, não sua refutação. Observa-se:

1. **Persistência de regimes:** Os grupos mantêm-se em faixas características de Ω ao longo do período, sem crossings abruptos generalizados
2. **Estabilidade estrutural:** Withdrawn não "colapsa" visivelmente; permanece em regime $\Omega \approx 1.0$ **estável mas inviável** até término do curso
3. **Flutuações controladas:** Variações temporais ocorrem dentro de envelopes bem definidos por coorte

Por que isso valida o framework: Um detector estrutural eficaz não deve disparar alarmes constantes. O objetivo é identificar **em qual regime o sistema está operando**, não sinalizar crashes fictícios. A ausência de transições abruptas em estudantes que eventualmente evadem confirma a tese educacional: **evasão é processo de permanência em regime estruturalmente inadequado**, não evento catastrófico pontual.

A linha horizontal em $\Omega = 1.0$ serve como referencial teórico. Sistemas que operam cronicamente próximos a este limiar, mesmo sem ultrapassá-lo sistematicamente, exibem **fragilidade estrutural latente** — pequenas perturbações podem induzi-los a transições irreversíveis. Esta é exatamente a dinâmica observada em dropouts reais: não há "momento do colapso", mas gradual inviabilização da permanência.

Síntese conceitual das visualizações:

As três figuras precedentes (2-4) estabelecem coletivamente um resultado teórico fundamental: **sistemas educacionais que rigidificam sua dinâmica informacional ($\Omega \rightarrow 1$) sem ganho proporcional de intensidade estrutural (Ξ) entram em regime Katashi — estado persistente, localmente funcional, mas globalmente inviável**. Este resultado possui três implicações críticas:

1. **Katashi é estado, não evento**: Diferentemente de modelos de alerta baseados em limiares pontuais de desempenho, detectamos **regimes operacionais persistentes** caracterizados por invariantes topológicos
2. **Separação sem supervisão**: A discriminação entre coortes emerge da geometria intrínseca dos padrões de engajamento, sem uso de labels durante computação
3. **Universalidade potencial**: O diagrama $\Xi \times \Omega$ sugere estrutura de fases análoga a transições termodinâmicas, potencialmente generalizável para outros domínios (finanças, LLMs, redes sociais)

4.8 Robustez paramétrica e validação estatística

Para confirmar que os padrões observados não são artefatos de escolhas metodológicas específicas, realizamos análise de sensibilidade paramétrica.

Variação de janela temporal:

Os experimentos foram replicados com janelas de $w = 6$ e $w = 10$ semanas. Os resultados qualitativos permaneceram estáveis: ordem temporal de cruzamentos (Fail antes de Pass antes de Distinction) manteve-se consistente, e razões de sincronização preservaram suas magnitudes relativas (Distinction $\ll$ Pass $\approx$ Fail). Isto indica que os sinais detectados refletem dinâmica intrínseca do sistema, não viés de escala.

Métodos de agregação de ensemble:

Testamos três estratégias de seleção de período CALM: minimum score, maximum score, e all candidates. Embora valores absolutos de θ variem ($\sim \pm 5\%$), a ordenação relativa entre coortes e o padrão de lead times permaneceram invariantes. Especificamente, o contraste

entre $\Delta t_{\text{Distinction}}$ (~7 dias) e Δt_{Pass} (~77 dias) persistiu em todas as configurações testadas.

CALM fixo vs. CALM por coorte:

Conforme reportado na Tabela 2, fixar um período CALM universal resulta em convergência de θ para ~0.88-1.06 em todas as coortes. Este resultado **valida a hipótese central**: θ mede distância a referencial estrutural, enquanto a classificação emerge da **dinâmica temporal** de cruzamentos. O fato de que padrões temporais persistem mesmo com normalização comum demonstra robustez fundamental da abordagem.

Testes estatísticos de diferenças:

Para confirmar significância das diferenças observadas, aplicamos testes não-paramétricos:

Teste de Kruskal-Wallis para diferenças entre grupos:

- Δt_{total} : $H = 38.7$, $p < 0.001$ (diferença altamente significativa)
- $\max(\Omega)$: $H = 31.2$, $p < 0.001$
- $\text{std}(\Xi)$: $H = 24.8$, $p < 0.001$

Testes post-hoc de Mann-Whitney (pairwise):

- Distinction vs Pass (Δt_{total}): $U = 0.0$, $p < 0.001$
- Distinction vs Fail (Δt_{total}): $U = 0.0$, $p < 0.001$
- Fail vs Pass (Δt_{total}): $U = 12.5$, $p = 0.041$

Todas as comparações confirmam que a coorte distinction é **estatisticamente distinta** das demais em termos de dinâmica temporal, com tamanho de efeito muito grande (Cohen's $d > 2.0$ para Distinction vs outros).

Síntese: Os padrões reportados são robustos a variações metodológicas razoáveis, estatisticamente significativos, e replicáveis sob diferentes configurações. Isto fortalece a interpretação de que representam fenômenos reais das trajetórias de aprendizagem, não artefatos analíticos.

4.9 Curva ROC e capacidade preditiva

Construímos classificadores simples usando apenas lead time (Δt_{total}) como feature:

Classificação binária: Distinction vs Rest

- Threshold: $\Delta t_{\text{total}} < 14$ dias $\rightarrow$ predição = Distinction
- Acurácia: 0.95
- Precision: 0.89

- Recall: 1.00
- F1-score: 0.94
- AUC-ROC: 0.98

Classificação binária: Fail vs Pass

- Threshold: $\Delta t_{\text{total}} < 70$ dias $\rightarrow$ predição = Fail
- Acurácia: 0.78
- AUC-ROC: 0.81

Estes resultados demonstram que **lead time possui valor preditivo substancial**, superando muitos modelos baseline de *learning analytics* que usam dezenas de features.

5 DISCUSSÃO

5.1 Interpretação teórica: crises como bifurcações

Os resultados empíricos suportam fortemente a interpretação de crises educacionais como **transições de fase em sistemas dissipativos**:

5.1.1 Estudantes reprovados: deterioração gradual

O padrão observado em fail — sinais precoces (início junho) com lead time moderado (63 dias) — é consistente com **bifurcação suave** onde o sistema gradualmente se afasta do atrator estável:

- Φ aumenta progressivamente (estrutura se fragiliza)
- Ξ diminui (complexidade topológica reduz)
- Ω cresce linearmente até cruzar limiares

Mecanismo proposto: feedback negativo entre dificuldade percebida e engajamento. Estudantes enfrentando dificuldades reduzem interação, o que por sua vez reduz aprendizagem, amplificando a dificuldade (círculo vicioso).

5.1.2 Estudantes aprovados: estabilidade prolongada

Pass apresenta lead time máximo (77 dias) e transição mais suave. O sistema resiste a instabilidades:

- Flutuações em Φ são amortecidas
- Ξ permanece relativamente constante

- Ω cresce lentamente

Mecanismo proposto: feedback positivo entre compreensão e engajamento. Estudantes que compreendem material engajam mais, o que reforça aprendizagem (círculo virtuoso). Sistema possui "inércia" estrutural que estabiliza contra perturbações.

5.1.3 Estudantes com distinção: bifurcação explosiva

O padrão de distinction — sinais tardios (agosto) mas cascata sincronizada (7 dias) — é consistente com **bifurcação supercrítica** ou **transição de primeira ordem**:

- Sistema permanece próximo ao atrator original por tempo prolongado
- Mudança paramétrica crítica desencadeia reorganização súbita
- Múltiplas variáveis transitam simultaneamente (daí sincronização)

Mecanismo proposto: **auto-organização crítica**. Estudantes de alto desempenho mantêm engajamento estruturado até período de avaliações finais, quando a pressão por excelência desencadeia reorganização do espaço de estados — aumento abrupto de intensidade, diversificação de estratégias, otimização de recursos. Este não é colapso, mas sim **transição para regime de maior complexidade funcional**.

Analogia física: transição líquido → gás (primeira ordem) vs transição paramagnético → ferromagnético (segunda ordem). Distinction exhibe características de primeira ordem: descontinuidade, latência, sincronização.

5.2 Conexão com literatura de learning analytics

Nossos resultados dialogam com múltiplas linhas da literatura:

5.2.1 Early warning systems

Modelos tradicionais de alerta precoce (ARNOLD; PISTILLI, 2012; TANES et al., 2011) focam em identificar estudantes em risco através de regressão logística sobre variáveis demográficas e de desempenho. Nossa abordagem complementa ao:

- Fornecer **interpretação mecanística** (bifurcações em sistemas dissipativos)
- Capturar **dinâmica temporal** (lead times, cascatas)
- Identificar não apenas risco, mas **tipo de trajetória**

Importante: distinction também cruza limiares críticos, mas o faz de forma qualitativamente diferente. Sistemas de alerta convencionais poderiam falso-positivamente sinalizar estes estudantes como "em risco", quando na verdade estão em transição positiva.

Comparação com métodos estatísticos tradicionais:

Diferentemente de abordagens baseadas em médias de notas, frequência de acesso, ou limiares de engajamento, o método Katashi detecta **transições estruturais** antes de degradação estatística convencional tornar-se evidente. Por exemplo:

- Modelos de regressão logística típicos requerem dados de desempenho (notas, submissões) que só ficam disponíveis após avaliações
- Nosso método detecta instabilidades usando apenas padrões de engajamento (cliques, recursos acessados), disponíveis continuamente
- Enquanto métodos supervisionados buscam maximizar acurácia preditiva pontual, nosso framework revela **processos** que podem informar timing e tipo de intervenção

Estudos futuros devem incluir benchmark direto com estado-da-arte (deep learning, gradient boosting) usando mesmas métricas de avaliação (AUC, F1-score, lead time de detecção).

5.2.2 Early warning signals em sistemas complexos

Nossa descoberta de assinaturas temporais distintas conecta-se com literatura emergente sobre **sinais de alerta precoce** (early warning signals) em transições críticas de sistemas complexos (SCHEFFER et al., 2009; DAKOS et al., 2008).

Scheffer e colaboradores demonstraram que sistemas próximos a transições críticas exibem fenômenos universais:

- **Critical slowing down:** aumento no tempo de recuperação após perturbações
- **Aumento de variância:** flutuações amplificadas próximo a bifurcação
- **Aumento de autocorrelação:** memória temporal estendida

Nossos resultados educacionais apresentam paralelos notáveis:

Fail (deterioração gradual):

- $\text{std}(\Xi) = 1.23$ (alto) → aumento de variância
- Lead time extenso (63d) → slowing down detectável
- Consistente com transição de segunda ordem (contínua)

Distinction (coerência explosiva):

- $\text{std}(\Xi) = 1.67$ (máximo) → variância pré-transição
- Lead time curto (7d) → ausência de slowing down
- Consistente com transição de primeira ordem (descontínua)

Pass (estabilidade):

- $\text{std}(\Xi) = 0.84$ (mínimo) → regime resiliente
- Flutuações amortecidas → longe de bifurcação

Esta conexão sugere que aprendizagem pode ser analisada usando ferramentas da física estatística de transições de fase, abrindo diálogo interdisciplinar com complex systems science.

5.2.3 Engagement analytics

Estudos de padrões de engajamento (KIZILCEC; PIECH; SCHNEIDER, 2013; COCEA; WEIBELZAHN, 2007) identificam "personas" comportamentais: completers, auditors, disengaging, sampling. Nossa análise topológica revela que:

- Estas personas podem corresponder a **atratores em espaço de estados**
- Transições entre personas são **bifurcações topologicamente detectáveis**
- Timing de transições é mais preditivo que estado em momento único

5.2.4 Teoria de auto-regulação da aprendizagem

Zimmerman (1990) e Pintrich (2000) propõem modelos de aprendizagem auto-regulada envolvendo ciclos de planejamento, monitoramento e ajuste. Nossa análise sugere que:

- Auto-regulação eficaz (pass) produz **estabilidade topológica**
- Falha de auto-regulação (fail) produz **fragmentação estrutural precoce**
- Auto-regulação excepcional (distinction) produz **reorganização adaptativa**

5.3 Implicações práticas para intervenções pedagógicas

Os resultados possuem implicações diretas para desenho de intervenções:

5.3.1 Timing de intervenções

Lead times sugerem "janelas de oportunidade" para intervenção:

- **Fail:** sinais aparecem ~9 semanas antes do final. Intervenção deve ocorrer já em junho (metade do curso).
- **Withdrawn:** sinais aparecem ~10 semanas antes. Intervenção deve focar em reengajamento e suporte psicossocial.
- **Pass:** sinais aparecem ~11 semanas antes, mas trajetória é auto-estabilizante. Intervenção pode ser mais leve.

5.3.2 Tipo de intervenção

Natureza da instabilidade sugere intervenções diferenciadas:

- **Fail (deterioração gradual):** tutoria intensiva, materiais de reforço, quebra de ciclo vicioso.
- **Withdrawn (desengajamento):** mentoria, reconexão com comunidade, redução de barreiras.
- **Distinction (reorganização):** suporte à intensificação, recursos avançados, desafios adicionais.

5.3.3 Sistemas de alerta adaptativos

Ao invés de threshold fixo ("risco/não-risco"), sistemas podem classificar estudantes em **regimes dinâmicos**:

- Regime estável (pass-like): monitoramento passivo
- Regime deterioração (fail-like): alerta nível 2, intervenção proativa
- Regime desengajamento (withdrawn-like): alerta nível 3, contato urgente
- Regime reorganização (distinction-like): suporte especializado

5.4 Limitações e validade externa

Reconhecimento explícito de limitações metodológicas:

Este estudo possui limitações importantes que devem ser consideradas na interpretação dos resultados:

5.4.1 Generalização

Os resultados derivam de análise de **um único curso** (AAA_2014J) de **uma instituição específica** (Open University, Reino Unido). Embora o OULAD seja dataset de referência internacional em learning analytics, a validação externa requer:

- Replicação em múltiplos cursos da mesma instituição
- Validação em instituições com perfis diferentes (públicas vs privadas, presenciais vs EaD)
- Testes em diferentes áreas do conhecimento (STEM vs humanidades)
- Análise em diferentes níveis educacionais (graduação vs pós-graduação)

Sem esta validação cruzada, não podemos afirmar que os padrões observados são universais.

5.4.2 Causalidade

Demonstramos **correlação temporal** (instabilidades topológicas precedem desfechos finais), mas não **causalidade**. Três interpretações alternativas são plausíveis:

1. **Interpretação causal direta** (nossa hipótese): Instabilidades estruturais *causam* deterioração de desempenho
2. **Causa comum**: Ambos (instabilidades e desfecho) são causados por terceira variável latente não observada (e.g., mudanças na vida pessoal do estudante, motivação intrínseca, suporte familiar)
3. **Causalidade reversa**: Percepção antecipada do desfecho futuro *influencia* comportamento presente (profecia autorrealizável)

Distinguir entre estas alternativas requer **estudos interventivos**: detectar instabilidade topológica, randomizar intervenção pedagógica, medir efeito causal no desfecho. Este desenho experimental está além do escopo do presente estudo observacional.

5.4.3 Nível de análise

Os resultados referem-se a **padrões coletivos de coortes**, não trajetórias individuais. Embora as assinaturas temporais sejam distintas entre grupos, a variabilidade intragrupo é substancial. Portanto:

- Não é possível prever com certeza o desfecho de um estudante individual baseado apenas em métricas topológicas
- O framework detecta **regime provável**, não destino determinístico
- Aplicações práticas devem incorporar incerteza e permitir múltiplas trajetórias possíveis

5.4.4 Sensibilidade a parâmetros

Embora tenhamos demonstrado robustez qualitativa (Seção 4.8), escolhas metodológicas quantitativas influenciam resultados:

- Largura de janela (w): janelas muito pequenas amplificam ruído, muito grandes suavizam transições
- Dimensão de homologia (k): dimensões maiores capturam estruturas mais complexas mas com custo computacional

- Percentis de limiar ($\theta_q = 0.95$): escolhas diferentes alteram timing de detecção

Análise de sensibilidade sistemática com varredura paramétrica completa permanece trabalho futuro.

5.4.5 Aspectos éticos e viés

Sistemas preditivos em educação levantam preocupações éticas fundamentais:

- **Profecia autorrealizável:** Estudante rotulado como "em risco" pode internalizar expectativa negativa, reduzindo autoeficácia
- **Viés algorítmico:** Se dados históricos refletem desigualdades estruturais, modelos perpetuam discriminação
- **Transparência e explicabilidade:** Estudantes têm direito de compreender como estão sendo avaliados
- **Autonomia e agência:** Intervenções automáticas podem minar autodeterminação do aprendiz

Qualquer implementação responsável deve: (a) usar predições para **oferta de suporte**, nunca punição; (b) garantir transparência e permitir contestação; (c) incluir opt-out voluntário; (d) monitorar continuamente equidade entre grupos demográficos.

Síntese crítica:

Este trabalho estabelece **prova de conceito** para detecção topológica de transições de regime em contexto educacional específico. A generalização e aplicação prática requerem validação adicional substancial, incluindo estudos causais, análises de equidade, e desenvolvimento de protocolos éticos de implementação.

5.5 Direções futuras

5.5.1 Validação cross-institucional

Aplicar Katashi em datasets de múltiplas instituições (CourseraResearchExportdata, edX, Khan Academy) para testar universalidade dos padrões.

5.5.2 Modelos preditivos temporais

Combinar métricas topológicas com modelos sequence-to-sequence (LSTM, Transformers) para predição de trajetória completa, não apenas desfecho final.

5.5.3 Intervenções adaptativas

Desenvolver sistemas de recomendação que sugiram recursos, atividades ou conexões sociais baseadas em regime topológico atual.

5.5.4 Análise causal

Usar técnicas de inferência causal (propensity score matching, instrumental variables, regression discontinuity) para isolar efeito causal das instabilidades topológicas.

5.5.5 Interpretabilidade via attention

Implementar mecanismos de atenção para identificar quais variáveis (recursos, horários, tipos de atividade) mais contribuem para instabilidades detectadas.

5.5.6 Comparação com métodos estado-da-arte

Benchmarking rigoroso contra modelos recentes: deep learning (He et al., 2020), gradient boosting (Lu et al., 2017), ensemble methods (Márquez-Vera et al., 2016).

6 CONCLUSÃO

Este trabalho demonstrou a viabilidade e utilidade de **análise topológica de dados** para detecção precoce de risco de evasão estudantil. O framework Katashi, aplicado ao Open University Learning Analytics Dataset, revelou que:

Descobertas principais:

1. **Crises educacionais são processos topológicos detectáveis:** Instabilidades estruturais precedem manifestações comportamentais em 7-77 dias, dependendo do regime.
2. **Diferentes desfechos possuem assinaturas temporais distintas:** Fail (deterioração gradual, 63d), Pass (estabilidade prolongada, 77d), Distinction (coerência explosiva, 7d), Withdrawn (desengajamento, ~68d).
3. **Lead time é discriminante superior:** Métrica de tempo entre primeiro sinal e confirmação de crise supera uso de θ estático, demonstrando que **dinâmica temporal** possui mais informação que **distância a referencial**.
4. **Coerência explosiva caracteriza excelência:** Estudantes de distinção não evitam crises, mas atravessam reorganização estrutural súbita onde múltiplas variáveis transitam sincronizadamente.

5. Fundamentação teórica sólida: Resultados são consistentes com teoria de estruturas dissipativas (Prigogine), sugerindo que aprendizagem é fenômeno de auto-organização em sistemas longe do equilíbrio.

Contribuições:

Metodológica: Primeiro framework de análise topológica de séries temporais educacionais com implementação open-source e documentação completa.

Teórica: Conexão formal entre learning analytics e física de sistemas complexos, estabelecendo crises educacionais como bifurcações em sistemas dissipativos informacionais.

Prática: Métricas de lead time permitem desenho de intervenções pedagógicas tempestivas e diferenciadas por regime dinâmico.

Limitações reconhecidas:

- Validação em curso único
- Ausência de intervenção experimental
- Sensibilidade a escolha de parâmetros não completamente caracterizada
- Questões éticas de implementação requerem atenção cuidadosa

Trabalho futuro:

Validação cross-institucional, desenvolvimento de modelos preditivos temporais, implementação de sistemas de intervenção adaptativa, e análise causal rigorosa são próximos passos naturais. Adicionalmente, extensão para outros domínios (saúde mental, desempenho organizacional, mercados financeiros) pode revelar se as assinaturas topológicas descobertas representam princípios universais de dinâmica de sistemas informacionais.

Mensagem final:

A análise topológica não substitui métodos estatísticos tradicionais, mas os **complementa** ao capturar aspectos estruturais e temporais invisíveis a médias e regressões. Assim como microscópios revelaram estruturas celulares invisíveis a olho nu, análise topológica revela estruturas dinâmicas em espaços de alta dimensão que métodos convencionais não conseguem perceber. Este trabalho oferece evidência de que a "forma" dos dados — sua topologia — contém informação preditiva e explicativa fundamental para compreender e apoiar trajetórias de aprendizagem.

REFERÊNCIAS

- ARNOLD, K. E.; PISTILLI, M. D. Course signals at Purdue: Using learning analytics to increase student success. In: PROCEEDINGS OF THE 2ND INTERNATIONAL CONFERENCE ON LEARNING ANALYTICS AND KNOWLEDGE, 2012. Anais... New York: ACM, 2012. p. 267-270.
- BEAN, J. P. Dropouts and turnover: The synthesis and test of a causal model of student attrition. **Research in Higher Education**, v. 12, n. 2, p. 155-187, 1980.
- CARLSSON, G. Topology and data. **Bulletin of the American Mathematical Society**, v. 46, n. 2, p. 255-308, 2009.
- COCEA, M.; WEIBELZAH, S. Eliciting motivation knowledge from log files towards motivation diagnosis for adaptive systems. In: USER MODELING, 2007. Anais... Berlin: Springer, 2007. p. 197-206.
- DAKOS, V. et al. Slowing down as an early warning signal for abrupt climate change. **Proceedings of the National Academy of Sciences**, v. 105, n. 38, p. 14308-14312, 2008.
- DEKKER, G. W.; PECHENIZKIY, M.; VLEESHOUWERS, J. M. Predicting students drop out: A case study. In: EDUCATIONAL DATA MINING, 2009. Anais... 2009. p. 41-50.
- EDELSBRUNNER, H.; HARER, J. **Computational topology: An introduction**. Providence: American Mathematical Society, 2010.
- EDELSBRUNNER, H.; LETSCHER, D.; ZOMORODIAN, A. Topological persistence and simplification. **Discrete & Computational Geometry**, v. 28, n. 4, p. 511-533, 2002.
- HE, J. et al. Early prediction of at-risk students using machine learning techniques. In: INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE IN EDUCATION, 2020. Anais... Springer, 2020. p. 135-140.
- KELLER, J. M.; SUZUKI, S. Use of fuzzy sets in student modeling. In: INTELLIGENT TUTORING SYSTEMS, 1988. Anais... 1988. p. 34-39.
- KIZILCEC, R. F.; PIECH, C.; SCHNEIDER, E. Deconstructing disengagement: Analyzing learner subpopulations in massive open online courses. In: LEARNING ANALYTICS AND KNOWLEDGE, 2013. Anais... ACM, 2013. p. 170-179.
- KUZILEK, J.; HLOSTA, M.; ZDRAHAL, Z. Open University Learning Analytics Dataset. **Scientific Data**, v. 4, 170171, 2017.

LU, O. H. et al. Applying learning analytics for improving students engagement and learning outcomes in an MOOCs enabled collaborative programming course. **Interactive Learning Environments**, v. 25, n. 2, p. 220-234, 2017.

LYKOURENTZOU, I. et al. Dropout prediction in e-learning courses through the combination of machine learning techniques. **Computers & Education**, v. 53, n. 3, p. 950-965, 2009.

MACFADYEN, L. P.; DAWSON, S. Mining LMS data to develop an "early warning system" for educators: A proof of concept. **Computers & Education**, v. 54, n. 2, p. 588-599, 2010.

MARIA, C. et al. The Gudhi library: Simplicial complexes and persistent homology. In: INTERNATIONAL CONGRESS ON MATHEMATICAL SOFTWARE, 2014. Anais... Springer, 2014. p. 167-174.

MÁRQUEZ-VERA, C. et al. Predicting school failure and dropout by using data mining techniques. **IEEE Revista Iberoamericana de Tecnologías del Aprendizaje**, v. 11, n. 2, p. 66-73, 2016.

NICOLIS, G.; PRIGOGINE, I. **Self-organization in nonequilibrium systems**. New York: Wiley, 1977.

NICOLIS, G.; PRIGOGINE, I. **Exploring complexity: An introduction**. New York: W.H. Freeman, 1989.

PINTRICH, P. R. The role of goal orientation in self-regulated learning. In: BOEKAERTS, M.; PINTRICH, P. R.; ZEIDNER, M. (Ed.). **Handbook of self-regulation**. San Diego: Academic Press, 2000. p. 451-502.

PRIGOGINE, I. Time, structure, and fluctuations. **Science**, v. 201, n. 4358, p. 777-785, 1977.

PRIGOGINE, I.; STENGERS, I. **Order out of chaos: Man's new dialogue with nature**. New York: Bantam Books, 1984.

ROMERO, C.; VENTURA, S. Educational data mining: A review of the state of the art. **IEEE Transactions on Systems, Man, and Cybernetics, Part C**, v. 40, n. 6, p. 601-618, 2010.

ROVAI, A. P. In search of higher persistence rates in distance education online programs. **The Internet and Higher Education**, v. 6, n. 1, p. 1-16, 2003.

SCHEFFER, M. et al. Early-warning signals for critical transitions. **Nature**, v. 461, p. 53-59, 2009.

SIEMENS, G.; LONG, P. Penetrating the fog: Analytics in learning and education. **EDUCAUSE Review**, v. 46, n. 5, p. 30-40, 2011.

TANES, Z. et al. Experimental evaluation of Signals: Helping students succeed. **EDUCAUSE Quarterly**, v. 34, n. 4, 2011.

TINTO, V. Dropout from higher education: A theoretical synthesis of recent research. **Review of Educational Research**, v. 45, n. 1, p. 89-125, 1975.

VAN NES, E. H.; SCHEFFER, M. Slow recovery from perturbations as a generic indicator of a nearby catastrophic shift. **The American Naturalist**, v. 169, n. 6, p. 738-747, 2007.

ZIMMERMAN, B. J. Self-regulated learning and academic achievement: An overview. **Educational Psychologist**, v. 25, n. 1, p. 3-17, 1990.

APÊNDICE A — Código Python do Framework Katashi

```

"""
Katashi Framework v1.0
Topological Data Analysis for Educational Time Series
"""

import numpy as np
import pandas as pd
import gudhi
from scipy.stats import ttest_rel
from sklearn.preprocessing import StandardScaler

class KatashiAnalyzer:
    """
    Framework para análise topológica de séries temporais educacionais.
    """

    def __init__(self, window=10, step=1, k=4):
        self.window = window
        self.step = step
        self.k = k
        self.metrics = []

    def compute_persistence(self, data_window):
        """
        Computa persistência homológica usando complexo de Vietoris-Rips.
        """
        # Normalizar janela
        scaler = StandardScaler()
        normalized = scaler.fit_transform(data_window)

        # Construir complexo simplicial
        rips = gudhi.RipsComplex(points=normalized, max_edge_length=2.0)
        simplex_tree = rips.create_simplex_tree(max_dimension=self.k)

        # Computar persistência
        simplex_tree.compute_persistence()

        # Extrair diagramas
        diagrams = {}
        for dim in range(self.k):
            diagrams[dim] = simplex_tree.persistence_intervals_in_dimension(dim)

        return diagrams

    def compute_topological_metrics(self, diagrams):

```

```

"""
Computa métricas agregadas a partir de diagramas de persistência.
"""

metrics = {}

# Xi: Complexidade topológica
xi = 0
for dim, intervals in diagrams.items():
    if len(intervals) > 0:
        persistences = intervals[:, 1] - intervals[:, 0]
        persistences = persistences[persistences < np.inf]
        if len(persistences) > 0:
            xi += np.sum(persistences) * (dim + 1) # Ponderar por dimensão

metrics['Xi'] = xi

# Phi: Fragilidade estrutural
total_features = sum(len(intervals) for intervals in diagrams.values())
if total_features > 0:
    low_persistence = 0
    for intervals in diagrams.values():
        if len(intervals) > 0:
            persistences = intervals[:, 1] - intervals[:, 0]
            persistences = persistences[persistences < np.inf]
            low_persistence += np.sum(persistences < 0.1)
    metrics['Phi'] = low_persistence / total_features
else:
    metrics['Phi'] = 0

# Eta: Entropia topológica
all_persistences = []
for intervals in diagrams.values():
    if len(intervals) > 0:
        persistences = intervals[:, 1] - intervals[:, 0]
        persistences = persistences[persistences < np.inf]
        all_persistences.extend(persistences)

if len(all_persistences) > 0:
    all_persistences = np.array(all_persistences)
    probs = all_persistences / np.sum(all_persistences)
    metrics['Eta'] = -np.sum(probs * np.log(probs + 1e-10))
else:
    metrics['Eta'] = 0

return metrics

```

```
def analyze_timeseries(self, data):  
    """  
    Análise completa de série temporal.  
    """  
    results = []  
  
    for i in range(0, len(data) - self.window, self.step):  
        window_data = data[i:i+self.window]  
  
        # Computar persistência  
        diagrams = self.compute_persistence(window_data)  
  
        # Métricas topológicas  
        metrics = self.compute_topological_metrics(diagrams)  
        metrics['timestamp'] = i  
  
        results.append(metrics)  
  
    return pd.DataFrame(results)
```

DECLARAÇÃO DE CONFLITO DE INTERESSES

O autor declara não haver conflito de interesses.

AGRADECIMENTOS

Ao Open University pela disponibilização do OULAD como recurso público para pesquisa em learning analytics.
